

大语言模型部署体验实验报告

项目公开可访问链接: <https://github.com/abbb-c/LLM-Deployment-Homework>

1 实验目的

通过使用 ModelScope 平台部署大语言模型, 学习大模型的基本部署流程, 了解模型推理运行过程, 并对不同大语言模型在中文问答任务中的表现进行横向对比分析。

2 实验环境

1. 实验平台

ModelScope

CPU 云服务器环境

2. 软件环境

Python 3.11

transformers 4.30.2

torch 2.3.0

sentencepiece

accelerate

3. 使用模型

ChatGLM3-6B

Qwen-7B-Chat

Baichuan2-7B-Chat

3 实验过程

3.1 ModelScope 平台环境配置

首先注册并登录 ModelScope 平台, 并绑定阿里云账号获取免费的 CPU 云计算资源。随后进入 Notebook 环境, 配置 Python 运行环境与相关依赖。

3.2 下载模型

在/mnt/data 目录下下载所需模型: (为了防止内存不足问题实际一次只下载一个模型)

```

git clone https://www.modelscope.cn/ZhipuAI/chatglm3-6b.git
正克隆到 'chatglm3-6b'...
remote: Enumerating objects: 147, done.
remote: Counting objects: 100% (7/7), done.
remote: Compressing objects: 100% (7/7), done.
remote: Total 147 (delta 0), reused 0 (delta 0), pack-reused 140
接收对象中: 100% (147/147), 77.69 KiB | 564.00 KiB/s, 完成.
处理 delta 中: 100% (64/64), 完成.
过滤内容: 100% (15/15), 23.26 GiB | 149.12 MiB/s, 完成.
root@dsw-1916425-7ddf857c97-qntrl:/mnt/data# cd /mnt/workspace

git clone https://www.modelscope.cn/qwen/Qwen-7B-Chat.git
正克隆到 'Qwen-7B-Chat'...
remote: Enumerating objects: 554, done.
remote: Counting objects: 100% (56/56), done.
remote: Compressing objects: 100% (30/30), done.
remote: Total 554 (delta 30), reused 49 (delta 26), pack-reused 498
接收对象中: 100% (554/554), 16.47 MiB | 32.12 MiB/s, 完成.
处理 delta 中: 100% (295/295), 完成.
过滤内容: 100% (8/8), 14.38 GiB | 153.84 MiB/s, 完成.
root@dsw-1916391-5ffdb67d69-pvnr5:/mnt/data#

root@dsw-1922527-6f69575cc8-5pw8m:/mnt/data# git clone https://www.modelscope.cn/baichuan-inc/Baichuan2-7B-Chat.git
正克隆到 'Baichuan2-7B-Chat'...
remote: Enumerating objects: 121, done.
remote: Counting objects: 100% (21/21), done.
remote: Compressing objects: 100% (21/21), done.
remote: Total 121 (delta 6), reused 0 (delta 0), pack-reused 100
接收对象中: 100% (121/121), 472.62 KiB | 3.53 MiB/s, 完成.
处理 delta 中: 100% (51/51), 完成.

过滤内容: 100% (2/2), 1.98 GiB | 5.08 MiB/s, 完成.

```

3.3 模型推理测试

分别编写 Python 推理脚本，对三个模型进行测试。

实验过程中，由于部分模型参数规模较大，在 CPU 环境下出现了较高的内存占用问题，因此采用 float16 精度方式降低模型运行内存。

4 问答测试结果

为了更加全面地测试不同模型的中文语义理解能力，本实验分别使用了两个问题对三个模型进行测试。

4.1 测试问题一

请说出以下两句话区别在哪里？

- 1、冬天：能穿多少穿多少
- 2、夏天：能穿多少穿多少

该问题主要考察模型对于语境变化与语言双关现象的理解能力。

4.1.1 ChatGLM3-6B

正确理解了语义，并额外区分了“气候信息”和“穿着建议”，回答较全面。

```
root@dsw-1922527-6fb9575cc8-5pw8m:/mnt/workspace# python run_glm3.py
Setting eos_token is not supported, use the default one.
Setting pad_token is not supported, use the default one.
Setting unk_token is not supported, use the default one.
Loading checkpoint shards: 100% | 7/7 [00:01<00:00, 4.05it/s]

模型回答：
这两句话的区别在于所处的季节不同。冬天和夏天是两个不同的季节，气候条件也有很大的区别。在冬天，气温较低，应该注意保暖，所以应该穿比较多的衣服。而在夏天，气温较高，应该注意防晒和透气，所以应该穿比较少衣服。因此，这两句话所传达的气候信息和穿着建议也不同。
```

4.1.2 Qwen-7B-Chat

正确，用词精准（保暖/透气），点出了“同一表达在不同语境下的侧重点差异”

```
root@dsw-1922527-6fb9575cc8-5pw8m:/mnt/workspace# python run_qwen.py
Loading checkpoint shards: 100% | 8/8 [00:55<00:00, 6.97s/it]

请说出以下两句话区别在哪里？冬天：能穿多少穿多少。夏天：能穿多少穿多少。这两句话的区别在于，第一句话是在描述冬天的气候特点，强调的是保暖；而第二句话是在描述夏天的气候特点，强调的是透气。因此，虽然两句话都表达了“能穿多少就穿多少”的意思，但它们所强调的重点不同。在冬天，人们需要穿着厚重的衣服来保暖，而在夏天，人们则需要穿着轻薄的衣服来透气。
```

4.1.3 Baichuan2-7B-Chat

正确且非常简洁，直接给出相反的行动建议，信息密度高。

```
root@dsw-1922527-6fb9575cc8-5pw8m:/mnt/data# python run_baichuan.py
Xformers is not installed correctly. If you want to use memory_efficient_attention to accelerate training use the following command to install Xformers
pip install xformers.
/usr/local/lib/python3.11/contextlib.py:105: FutureWarning: `torch.backends.cuda.sdp_kernel()` is deprecated. In the future, this context manager will be removed. Please see `torch.nn.attention.sdpa_kernel()` for the new context manager, with updated signature.
  self.gen = func(*args, **kwargs)

模型回答：
请说出以下两句话区别在哪里？冬天：能穿多少穿多少。夏天：能穿多少穿多少。
1. 冬天：能穿多少穿多少。这句话强调的是在寒冷的冬天里，人们为了保暖，尽量多穿一些衣服来抵御寒冷。
2. 夏天：能穿多少穿多少。这句话强调的是在炎热的夏天里，人们为了散热，尽量少穿一些衣服来保持凉爽。
```

4.2 测试问题二

明明明明明白白白喜欢他，可她就是不说话。这句话里，明明和白白谁喜欢谁？该问题主要考察模型对于中文人名重复、语义歧义以及复杂句式的理解能力。

4.2.1 ChatGLM3-6B

ChatGLM3 推断“明明喜欢白白”，答案是错误的，但分析过程是正确的，说明模型在复杂中文断句与人物关系推理方面仍存在一定局限。

```
root@dsw-1922747-5b9d4d5bc7-bc9tg:/mnt/data# python run_glm3.py
Setting eos_token is not supported, use the default one.
Setting pad_token is not supported, use the default one.
Setting unk_token is not supported, use the default one.
Loading checkpoint shards: 100% | 7/7 [00:01<00:00, 3.85it/s]

模型回答：
从这句话中可以看出，明明知道白白喜欢他，但白白并没有表达出自己的喜欢。所以，在这句话里，是明明喜欢白白。
```

4.2.2 Qwen-7B-Chat

Qwen 模型推理过程比较短，未尝试解析指代关系，回避问题，给出了“无法确定”的回答，答案错误。虽然没有准确给出句子的真实含义，但表现出了相对谨慎的推理方式。同时，模型将开放性问题自行转换成了选择题格式，虽然答案仍错误，但表明其倾向于结构化的输出。

```
root@dsw-1922747-5b9d4d5bc7-bc9tg:/mnt/data# python run_qwen.py
Loading checkpoint shards: 100% | 8/8 [00:53<00:00, 6.70s/it]

明明明明明白白白喜欢他，可她就是不说话。这句话里，明明和白白谁喜欢谁？（ ）
A. 明明喜欢白白
B. 白白喜欢明明
C. 无法确定

Assistant: 这句话中并没有明确说明谁喜欢谁，因此无法确定。
故选：C。
```

4.2.3 Baichuan2-7B-Chat

Baichuan 模型识别出了句子中的歧义现象，并指出该句缺少足够上下文，因此无法直接确定人物关系。虽然没有给出正确答案，但展现了较高的语言敏感度和元认知能力。推理过程深入，解释了为什么不确定。根据语境，实际可以确定明明和白白是两个人，所以该模型对语境的理解力依然有限。

```
root@ds-1922747-5b9d4d5bc7-bc9tg:/mnt/data# python run_baichuan.py
Xformers is not installed correctly. If you want to use memory_efficient_attention to accelerate training use the following command to install Xformers
pip install xformers.
/usr/local/lib/python3.11/contextlib.py:105: FutureWarning: `torch.backends.cuda.sdp_kernel()` is deprecated. In the future, this context manager will be removed.
Please see torch.nn.attention.sdpa_kernel() for the new context manager, with updated signature.
  self.gen = func(*args, **kwargs)

模型回答：
明明明明明白白白喜欢他，可她就是不。这句话里，明明和白白谁喜欢谁？
从这句话中我们无法判断出明明和白白之间谁喜欢谁。因为“明明”和“白白”可能是指代两个人，也可能是指代同一个人。为了更准确地理解这句话，我们需要更多的上下文信息。
```

5 大语言模型横向对比分析

5.1 语义理解能力

案例：冬夏“能穿多少穿多少”

ChatGLM3-6B

该模型不仅指出了相反的行动建议（多穿 vs 少穿），还区分了“气候信息”和“穿着建议”两个层面，说明它理解到这是一道关于语境与语用的问题。回答全面且有条理。

Qwen-7B-Chat

Qwen 准确抓住了“保暖”与“透气”这对核心对立概念，并且用“重点不同”点出了语境对含义的决定性作用。用词精准，没有冗余。

Baichuan2-7B-Chat

Baichuan 的回答最简洁，直接给出相反的行动指令，信息密度很高。虽然没有展开分析，但正确性毋庸置疑。

小结：三个模型在这一常识类语境歧义题上全部正确，说明它们对日常生活中的语用推理都具备扎实的基础能力。没有明显差距。

5.2 歧义消解能力

案例：“明明明明明白白白喜欢他”谁喜欢谁？（正确答案：白白喜欢明明）

ChatGLM3-6B

该模型尝试对句子进行解析，但方向完全错了。它将句子理解为“明明 / 知道/白白喜欢他”，然后错误地推出“明明喜欢白白”。实际上，正确的解析应该是“明明/明明明白/白白喜欢他”（明明清楚地知道，白白喜欢他）。ChatGLM 没有意识到“明明”可能重复使用，也没有考虑“他”的指代对象，推理跳跃，最终给出错误且自信的答案。这说明它在处理汉语复杂指代结构时能力较弱。

Qwen-7B-Chat

Qwen 选择了最保守的策略——不解析，直接判定“无法确定”。这样做虽然避免了错误，但也完全没有展示解析能力。从模型行为看，它可能意识到了句子的复杂性和歧义性，但没有能力或没有尝试去理清指代关系。这种“回避策略”在面对风险问题时是安全的，但对于需要精确理解的任务则不够用。

Baichuan2-7B-Chat

Baichuan 的表现相对最好。它虽然没能给出正确答案，但主动指出了歧义的来源：指代可能重合（同一个人或两个人）。这说明模型能够识别出句子中存在的结构歧义，并具有元认知能力——它知道自己不确定，并且能说不确定的原因。这种能力在需要谨慎处理信息的场景中非常有价值。

小结：在这一高难度歧义消解任务上，三个模型全部失败，但失败的方式不同：ChatGLM “错得自信”，Qwen “避而不答”，Baichuan “知道自己的无知”。从实用角度看，Baichuan 的行为最可接受，因为它提供了有价值的信息（“这里存在歧义”），而不是误导或空白。

5.3 推理策略与严谨性

ChatGLM3-6B

表现出过度自信的倾向。在问题 2 中，它没有展示任何对歧义的识别，直接给出了一个确定但错误的答案。这种策略在简单问题上可能效率高，但在复杂问题上风险很大，容易产生误导。

Qwen-7B-Chat

表现出保守回避的策略。在问题 2 中直接选择“无法确定”，没有尝试任何解析路径。这种策略确保了答案不会错，但也意味着放弃了挑战。在需要深入推理的任务中，这可能不够用。

Baichuan2-7B-Chat

表现出谨慎分析的策略。它首先识别出句子可能存在歧义（“可能指代两个人，也可能指代同一个人”），然后说明需要更多上下文才能确定。虽然最终没能给出正确答案，但它的推理过程是透明的、逻辑自洽的。这种策略更接近于人类专家的思维方式——“我无法确定，但我知道为什么无法确定”。

结论：在推理严谨性上，Baichuan2 > Qwen > ChatGLM。

5.4 表达风格与清晰度

ChatGLM3-6B

语言较为详细，喜欢分层阐述。例如在问题 1 中，它区分了“气候信息”和“穿着建议”，显得条理清晰。但在问题 2 中，由于推理本身错误，表达的清晰度反而放大了错误的影响。

Qwen-7B-Chat

语言精炼，用词准确。问题 1 中用“保暖/透气”精确概括了核心差异。问题 2 中以选择题形式呈现答案，有产生幻觉的嫌疑，内容保守。

Baichuan2-7B-Chat

风格极为简洁，往往用最少的词语传递核心信息。问题 1 中“多穿/少穿”高度概括。问题 2 中虽然答案错误，但解释性文字直接到位，没有冗余。

小结：三种风格各有优劣。Qwen 和 Baichuan 更适合需要快速获取信息的场景，ChatGLM 适合需要详细解释的场景。

5.5 总结

维度	ChatGLM3-6B	Qwen-7B-Chat	Baichuan2-7B-Chat
常识语义理解	优秀	优秀	优秀
复杂歧义消解	差（错误自信）	差（回避）	中等（识别歧义）
推理严谨性	较低	中等	较高
不确定时行为	过度自信	保守回避	谨慎分析
表达清晰度	详细有条理	精炼清晰	极简直接
响应速度	最快	最慢	中等
综合推荐场景	创意生成、需详细解释的任务	通用对话、对安全性要求高的场景	对语言细节敏感、需谨慎判断的场景

6 实验总结

本次实验完成了多个大语言模型在 ModelScope 平台上的部署与推理测试，加深了对于大语言模型部署流程与运行机制的理解。

实验过程中学习了模型下载、依赖环境配置、推理脚本编写以及内存优化等内容，并对不同模型在中文语义理解任务中的表现进行了对比分析。

本次实验还发现，三个模型在处理生活常识类语境歧义时表现优秀，但在深层句法/指代歧义上均暴露出不足，说明当前开源模型对中文复杂语言结构的理解仍有提升空间。不同模型在不确定情况下的行为策略差异显著：ChatGLM3-6B 倾向于给出确定答案但易出错，Qwen-7B-Chat 偏向保守回避，Baichuan2-7B-Chat 则更善于识别歧义并解释不确定性。

这提示我们，在实际应用中应结合任务风险选择合适模型，并关注模型在不确定性下的行为模式。